数据库系统

LAB3: 数据库原型实现

陈世敏

（中科院计算所）

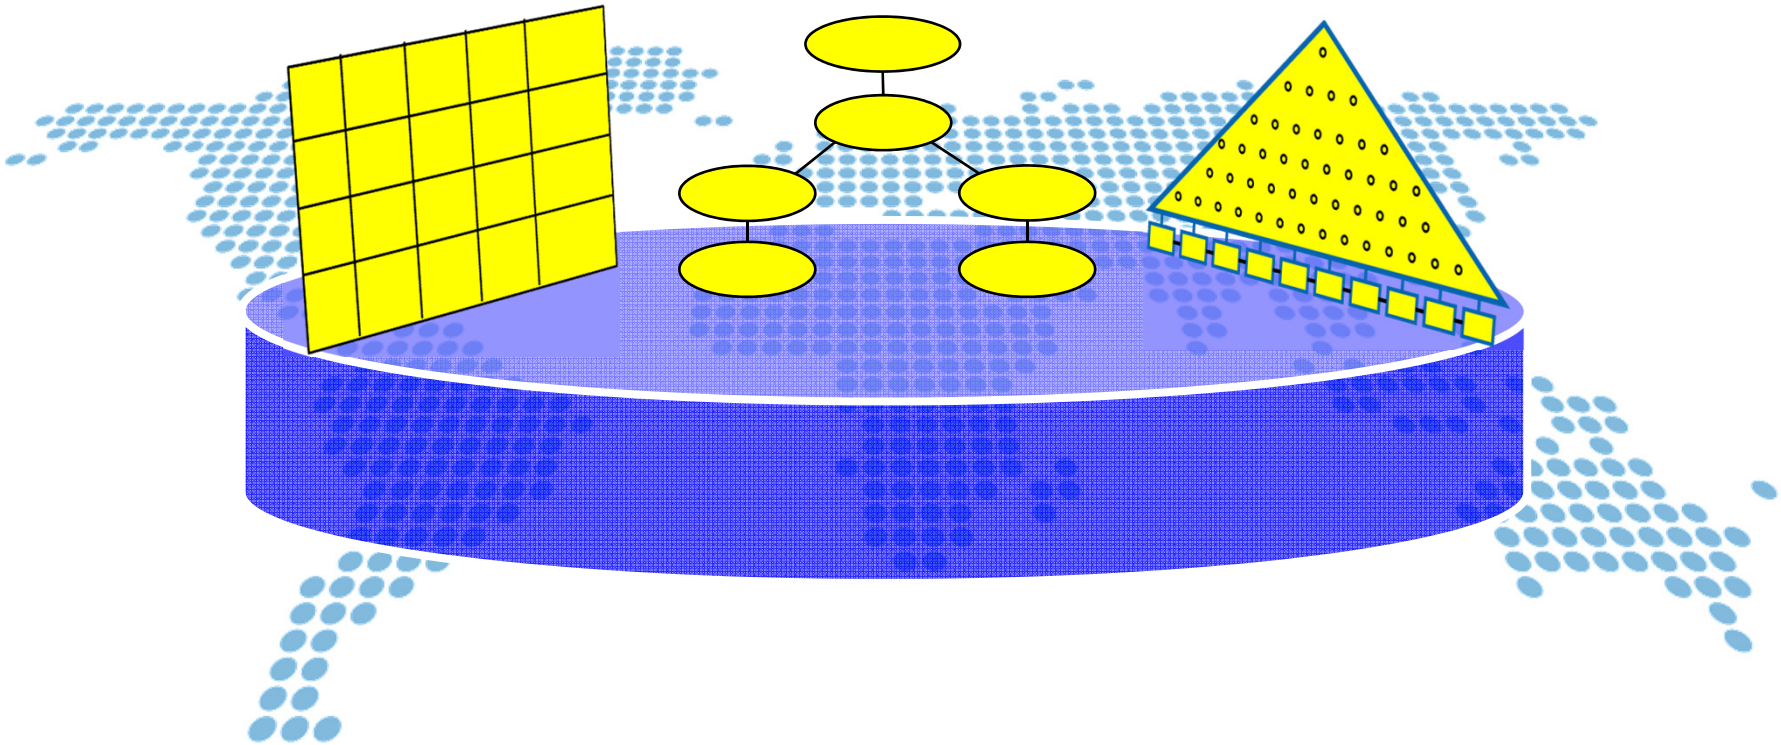

课程安排

- 13:30-13:50 Lab3说明（陈世敏）
- 13:50-14:20 AIMDB说明（陈乐滢）
- 14:20-16:10 当堂练习

课程安排

周次	内容	
第11周	查询处理（1）	
第12周，5月12日	实验2验收	
第13周，5月19日	实验3：分析型数据库系统实现布置（每组3人）	25%
第14周	查询处理（2）	
第15周	查询优化	
第16周，6月9日	事务处理	提交1
第17周	数据仓库；并行/分布式数据库等	
第18周，6月23日	实验3验收	提交2
第19-20周	期末考试	50%

实验3安排

- 内容：在一个原型内存数据库系统AimDB上实现select查询处理功能
  - 掌握多种关系运算的查询处理实现
- 本堂课：5月19日
  - 实验3具体要求
  - AimDB介绍、编程环境说明
- 6月9日（3周后）
  - 提交1：完成选择、投影、连接
- 6月23日（5周后）
  - 提交2：完成分组聚集、排序

AimDB 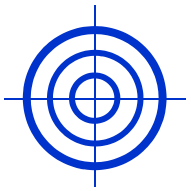

- An implementation of main memory DataBase
- 我们自己实现的一个简单的内存数据库原型
  - C/C++实现
  - Database, Table, Index的定义和实现
  - 数据类型和操作的支持：每个类型有一个class
- 预留了查询处理部分
  - 预留的调用接口
  - 定义了输入参数和返回值类型
  - 要求实验3实现查询处理部分

实验3：内存数据库中查询处理实现

- 支持Select语句的基础功能
  - 选择：过滤条件
  - 投影：提取部分列
  - 连接：找匹配的记录
  - 分组聚集：进行统计运算
  - 排序
- Select的内容将会形成一个结构体，作为调用参数
- 需要实现的是查询处理的功能

Select语句的子句

SELECT …

FROM …

WHERE …

GROUP BY …

HAVING …

ORDER BY …

每个子句中，最多出现4个子项

需求1：TableScan Operator

- 实现一个扫描Table的Operator
- 顺序访问给定Table的所有tuple

需求2：Where条件

- 最多有4个条件
- 条件之间是AND关系
  - （条件1）AND （条件2）…
- 两种形式的条件
  - 列名 op 常量
    - 记录在单独某一列上的属性值与一个常量进行比较
  - 列名1 op 列名2
    - 连接条件
- 可以使用数据类型的相关操作计算单个条件

需求3：FilterProject Operator

- 下层输入是tuple
- 对tuple实现过滤
- 并对满足过滤条件的tuple，进行投影
- 产生结果记录

需求4：From子句和2种Join Operator

- 最多4个Table
- 连接条件在where子句中给定
- HashJoin Operator
  - 当join key上没有index时
  - 采用Hash Join：可以用simple hash join实现
- IndexNestedLoopJoin Operator
  - 当至少一个表的join key上有hash index时
  - 直接用Index Nested Loop Join实现

需求5：Group By + Aggregation

- 实现GroupByAggr Operator
  - Group By的分组组别最多可以有4个列
  - Aggregation最多在4个列上计算
    - SUM, AVG, COUNT, MAX, MIN
  - 采用基于哈希的方式实现
    - 分组组别列➔Hash table的key
    - Hash table的value是一个指针，指向分组组别列和Aggregation的中间结果

需求6：在Group By之后可以有Having

- 构造query operator tree时，
  允许在GroupByAggr上有FilterProject

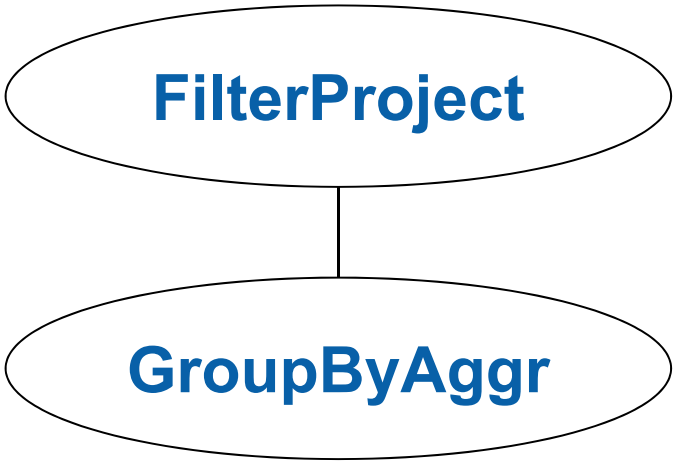

需求7：OrderBy Operator

- 排序的键最多包含4个列
- 全部是从小到大顺序
- 采用quick sort算法实现

需求8：Select子句输出

- 最多有4个列
- 有可能是Aggregation

需求9：采用Tuple-at-a-time方式计算

- 每个Operator实现
  - open
  - getNext
  - close
- 根据Select的内容，构造Operator Tree
- 确定具体的初始化参数

提示

- AimDB提供了hash table的class
- 可以用libc中的quicksort来实现排序
  - 也可以自己写quicksort算法

评分标准

- 总分：25分
  - 代码说明和注释，提交doxygen产生的pdf：3分
    - 注释需要对每个函数的实现进行说明
    - 是否确实实现了上述规定的Operator
    - 采用doxygen规定的格式（https://en.wikipedia.org/wiki/Doxygen）
    - 用doxygen产生pdf的程序设计文档
  - select语句：22分
    - 我们将产生22个测试，每一个测试占1分
    - 选择投影：5分
    - 连接：10分
    - 分组聚集：5分
    - 排序：2分
  - 提交代码，进行抄袭相似性检查
    - 如果发现抄袭，那么0分，并通知教务处
  - 我们验收时会给定输入，检查输出是否正确
- 提交：executor.cc，executor.h，pdf文档

时间节点

- 本堂课：5月19日
  - 发布实验3
- 6月9日（3周后）
  - 提交1：完成选择、投影、连接：15分
- 6月23日（5周后）
  - 提交2：完成分组聚集、排序：7分
  - 提交doxygen产生的程序设计文档：3分